

softmax 回归：定义—计算—作用—联系

学习笔记

2026 年 8 月 25 日

总览框架

softmax 回归和线性回归是同一个骨架的两个变体：

- (1) 线性层：把输入映射成“分数” $o = XW + b$
- (2) 概率解释：把分数变成概率 回归： $y \sim \mathcal{N}(o, \sigma^2)$ ；分类： $\text{softmax}(o)$
- (3) 最大似然损失：从概率推出损失 回归 $\rightarrow$ MSE；分类 $\rightarrow$ 交叉熵

1 网络结构： $o = XW + b$

1.1 定义

每个样本输出 C 个“分数” (logits)：

$$o_j = x \cdot w_j + b_j$$

矩阵形式：

$$o = XW + b, \quad X \in \mathbb{R}^{n \times d}, \quad W \in \mathbb{R}^{d \times C}, \quad o \in \mathbb{R}^{n \times C}$$

与线性回归完全同构，唯一区别： W 从向量 $\mathbb{R}^d$ 变成矩阵 $\mathbb{R}^{d \times C}$ ， b 从标量变成 C 维向量。

1.2 手算例子

3 个类别、2 维特征、一个样本 $x = [1, 2]$ ：

$$W = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & 2 \end{pmatrix}, \quad b = [0.1, -0.2, 0.3]$$

$$o = [1 \cdot 1 + 2 \cdot 0 + 0.1, \quad 1 \cdot 0 + 2 \cdot 1 - 0.2, \quad 1 \cdot (-1) + 2 \cdot 2 + 0.3] = [1.1, 1.8, 3.3]$$

2 softmax：分数 $\rightarrow$ 概率

2.1 定义

$$\hat{y}_j = \frac{\exp(o_j)}{\sum_{k=1}^C \exp(o_k)}$$

2.2 计算

$$o = [1.1, 1.8, 3.3], \quad \exp(o) = [3.0, 6.05, 27.1], \quad \sum = 36.2$$
$$\hat{y} = [0.083, 0.167, 0.749]$$

2.3 三个性质（缺一不可）

(1) 非负：exp 恒正 $\Rightarrow$ 概率不能为负。

(2) 和为 1： $\sum_j \hat{y}_j = \frac{\sum_j \exp(o_j)}{\sum_k \exp(o_k)} = 1 \Rightarrow$ 是合法概率分布。

(3) 保序放大： o_j 越大 $\hat{y}_j$ 越大；指数放大差距（ o 只差 1.5，概率却 0.75 vs 0.17）。

2.4 为什么用 exp

- 保证正数：指数函数恒正；
- 放大差距：softmax 是“软版 argmax”，最大分数经指数放大后几乎占据全部概率；
- 数学根源：exp 是多项分布的自然参数形式。

3 交叉熵损失

3.1 定义

$$L = -\log \hat{y}_y$$

其中 y 是真实类别， $\hat{y}_y$ 是模型给“正确类别”的概率；整批取平均。

与完整形式的联系（one-hot 独热编码）：真实标签用 one-hot 向量表示——正确类别的位置是 1，其余是 0。例如 3 类问题中，真实类别是第 2 类，则标签为 $y = [0, 0, 1]$ 。交叉熵的完整形式是对所有类别求和：

$$L = -\sum_k y_k \log \hat{y}_k$$

因为 one-hot 只有正确类别处 $y_k = 1$ 、其余 $y_k = 0$ ，求和展开后其余项全为零（ $0 \cdot \log \hat{y}_k = 0$ ），只剩正确类别那一项：

$$-\sum_k y_k \log \hat{y}_k \xrightarrow{\text{one-hot 只剩 } k=y \text{ 一项}} -\log \hat{y}_y$$

（第 4.2 节推导用的就是完整形式；两者完全等价。）

3.2 从最大似然推导（2.6 的落地）

第 1 步：似然。真实标签 y 是 one-hot，模型输出概率 $\hat{y}$ 。“模型预测对这个样本”的概率 = 给正确类别的概率 $\hat{y}_y$ 。整批数据（样本独立）的似然：

$$P = \prod_i \hat{y}_y^{(i)}$$

第 2 步：取负对数（乘积变求和、最大化变最小化）：

$$-\log P = -\sum_i \log \hat{y}_y^{(i)}$$

第 3 步：平均。

$$L = \frac{1}{n} \sum_i -\log \hat{y}_y^{(i)}$$

3.3 为什么不用 MSE

以 sigmoid 二分类为例，若 $L = (\sigma(o) - y)^2$ ，其梯度为：

$$\frac{\partial L}{\partial o} = 2(\sigma(o) - y) \cdot \sigma(o)(1 - \sigma(o))$$

当预测很离谱（ $y = 1$ 而 $\sigma(o) \rightarrow 0$ ）时，因子 $\sigma(o)(1 - \sigma(o)) \rightarrow 0$ ，**梯度消失**——模型错得越离谱反而越学不动。交叉熵的梯度里 $\exp$ 与 $\log$ 互相抵消，没有该饱和项：预测越错、梯度越大。

4 参数计算：梯度 = $\hat{y} - y$

4.1 结论

$$\frac{\partial L}{\partial o_j} = \hat{y}_j - y_j$$

梯度 = 预测概率 - 真实 one-hot，与线性回归 MSE 的梯度“预测 - 真实”对称。

4.2 完整推导

记 $L = -\sum_k y_k \log \hat{y}_k$ ， $\hat{y}_k = \frac{\exp(o_k)}{\sum_m \exp(o_m)}$ 。

由链式法则：

$$\frac{\partial L}{\partial o_j} = \sum_k \frac{\partial L}{\partial \hat{y}_k} \cdot \frac{\partial \hat{y}_k}{\partial o_j}$$

两项分别求。第一项（ $\log$ 的导数）：

$$\frac{\partial L}{\partial \hat{y}_k} = -\frac{y_k}{\hat{y}_k}$$

第二项：softmax 的雅可比（ δ_{kj} 为克罗内克符号， $k = j$ 时为 1）：

$$\frac{\partial \hat{y}_k}{\partial o_j} = \hat{y}_k (\delta_{kj} - \hat{y}_j)$$

代入并化简：

$$\begin{aligned}
 \frac{\partial L}{\partial o_j} &= \sum_k \left(-\frac{y_k}{\hat{y}_k} \right) \cdot \hat{y}_k (\delta_{kj} - \hat{y}_j) \\
 &= \sum_k -y_k (\delta_{kj} - \hat{y}_j) \\
 &= -y_j + \hat{y}_j \sum_k y_k \\
 &= -y_j + \hat{y}_j \cdot 1 \quad (\text{one-hot 各项和为 1}) \\
 &= \hat{y}_j - y_j
 \end{aligned}$$

核心作用：exp 与 log 在求导中互相抵消，得到最简梯度且无饱和项——这就是“softmax + 交叉熵”是黄金组合的原因。

4.3 参数更新

$$W \leftarrow W - \eta \cdot \frac{1}{n} X^\top (\hat{y} - y)$$

训练循环与线性回归完全一致：前向 → 交叉熵 → backward → 更新，仅把损失函数换成交叉熵。

5 与线性回归的对比

维度	线性回归	softmax 回归
任务	预测连续值	分类
输出	1 个数	C 个概率
参数	$W \in \mathbb{R}^d$	$W \in \mathbb{R}^{d \times C}$
输出变换	无	softmax
损失	$\text{MSE} = \frac{1}{n} \sum (o - y)^2$	$L = -\log \hat{y}_y$
概率解释	$y \sim \mathcal{N}(o, \sigma^2)$	$y \sim \text{Multinomial}(\hat{y})$
损失来源	高斯似然的负对数	多项似然的负对数
梯度	$\propto o - y$	$\hat{y} - y$
训练循环	zero_grad → backward → step	完全一样

6 统一的视角

两个模型本质是同一个模板：

模板 = 线性层 + 概率分布假设 + 最大似然损失

线性回归： $o = Xw + b \Rightarrow y \sim \mathcal{N}(o, \sigma^2) \Rightarrow \text{MSE}$

softmax： $o = XW + b \Rightarrow y \sim \text{Multinomial}(\text{softmax}(o)) \Rightarrow \text{交叉熵}$

核心结论：“损失函数 = 概率假设的负对数似然”。这是全书所有损失函数的底层逻辑：第 4 章以后的多层感知机、CNN、RNN 只是把“线性层”换成更深的网络，概率解释与损失套路原封不动。